

SISTEMA CACIF

Modelo de Datos

Versión 1.0

Lima, Mayo del 2026

Historial de Revisiones

Fecha	Versión	Descripción	Autor
12/05/2026	1.1	Versión inicial del modelo de datos	Fabrizio Mantari

Tabla de Contenidos

1. Introducción	4
1.1. Propósito	4
1.2. Alcance del Modelo	4
1.3. Convenciones	4
2. Diagrama Entidad-Relación	4
3. Especificación de Tablas	5
3.1. Estudiante	5
3.2. Conversación	5
3.3. Mensaje	6
3.4. Chunk Normativo	6
3.5. Fuente Citada	7
3.6. Documento Normativo	7
4. Descripción de Relaciones	8

1. Introducción

1.1. Propósito

Este documento describe el modelo de datos del sistema CACIF. Contiene el Diagrama Entidad-Relación (ER), la especificación detallada de cada tabla con sus atributos, tipos de datos, claves y restricciones.

1.2. Alcance del Modelo

El modelo cubre la base de datos relacional (PostgreSQL 16) que persiste:

- Identidad y sesiones de los estudiantes autenticados.
- Historial completo de conversaciones y mensajes del chatbot.
- Trazabilidad de los chunks normativos recuperados por el motor RAG.
- Catálogo de documentos normativos vigentes ingresados al sistema.

1.3. Convenciones

Convención	Descripción
PK	Primary Key — clave primaria de la tabla, tipo UUID v4 generado por la BD
FK	Foreign Key — referencia a la PK de otra tabla, con ON DELETE CASCADE donde aplica
UUID	Universally Unique Identifier — formato estándar para identificadores primarios
ENUM	Tipo enumerado definido en PostgreSQL con los valores válidos especificados
VECTOR(n)	Tipo de dato vectorial (pgvector) de n dimensiones, para embeddings del RAG
NO / SÍ	Indica si el campo admite valores nulos (SÍ = nullable, NO = NOT NULL)

2. Diagrama Entidad-Relación

El siguiente diagrama ER representa el modelo de datos relacional (PostgreSQL) y la referencia a la base vectorial:




Figura 1. Diagrama de Entidad - Relación

3. Especificación de Tablas

A continuación se detalla cada tabla con sus campos, tipos de dato, restricciones y descripción funcional.

3.1. Estudiante

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único generado por gen_random_uuid()
university_code	VARCHAR(12)			NO	Código de matrícula institucional, único por estudiante
full_name	VARCHAR(200)			NO	Nombre y apellidos completos según registro UNMSM
email	VARCHAR(150)			NO	Correo institucional (@unmsm.edu.pe), único en la tabla
created_at	TIMESTAMP WITH TZ			NO	Fecha/hora de primer acceso al sistema (UTC)
is_active	BOOLEAN			NO	TRUE si la cuenta está habilitada; default TRUE

3.2. Conversación

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único de la sesión de chat

Campo	Tipo	PK	FK	Nulable	Descripción
student_id	UUID		FK	NO	Referencia a ESTUDIANTE.id (ON DELETE CASCADE)
intent_type	ENUM			NO	Intención detectada: CU01 CU02 CU03 CU04
started_at	TIMESTAMP WITH TZ			NO	Timestamp de apertura de la conversación (UTC)
closed_at	TIMESTAMP WITH TZ			SÍ	Timestamp de cierre; NULL si la sesión sigue activa
total_messages	INTEGER			NO	Contador desnormalizado de mensajes, actualizado por trigger

3.3. Mensaje

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único del turno de diálogo
conversation_id	UUID		FK	NO	Referencia a CONVERSACION.id (ON DELETE CASCADE)
role	ENUM			NO	Emisor del turno: 'user' (estudiante) 'assistant' (CACIF)
content	TEXT			NO	Texto completo del mensaje en español
tokens_used	INTEGER			SÍ	Tokens consumidos al llamar al LLM (solo para rol=assistant)
rag_confidence	FLOAT			SÍ	Score promedio de similitud de los chunks recuperados (0-1)
sent_at	TIMESTAMP WITH TZ			NO	Timestamp exacto del envío (UTC)

3.4. Chunk Normativo

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único del fragmento normativo
document_id	UUID		FK	NO	Referencia a DOCUMENTO_NORMATIVO.id
source_document	VARCHAR(300)			NO	Nombre del PDF fuente (ej: 'Reglamento_VRI_2026.pdf')

Campo	Tipo	PK	FK	Nulable	Descripción
start_page	INTEGER			SÍ	Número de página donde inicia el fragmento en el PDF
end_page	INTEGER			SÍ	Número de página donde termina el fragmento
content	TEXT			NO	Texto del fragmento extraído, máx ~512 tokens
embedding	VECTOR(1536)			NO	Vector embedding de 1536 dimensiones (OpenAI ada-002)
version	VARCHAR(20)			NO	Versión del documento fuente (ej: '2026-v1')
valid_from	TIMESTAMP WITH TZ			NO	Fecha desde la que este chunk es válido
created_at	TIMESTAMP WITH TZ			NO	Fecha de ingesta del chunk al sistema

3.5. Fuente Citada

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único de la cita
message_id	UUID		FK	NO	Referencia a MENSAJE.id (ON DELETE CASCADE)
chunk_id	UUID		FK	NO	Referencia a CHUNK_NORMATIVO.id
position	INTEGER			NO	Orden del chunk en el contexto enviado al LLM (1=más relevante)
similarity_score	FLOAT			NO	Similitud coseno entre el embedding de la consulta y el chunk

3.6. Documento Normativo

Campo	Tipo	PK	FK	Nulable	Descripción
id	UUID	PK		NO	Identificador único del documento
name	VARCHAR(300)			NO	Nombre oficial del documento (ej: 'Reglamento del VRI')
type	ENUM			NO	Categoría: reglamento resolucion directiva
official_code	VARCHAR(100)			SÍ	Ej: RR N° 000947-2026-R

Campo	Tipo	PK	FK	Nulable	Descripción
souce_url	VARCHAR(500)			SÍ	URL pública del documento en el portal UNMSM
published_att	DATE			NO	Fecha de emisión oficial del documento
is_active	BOOLEAN			NO	TRUE si el documento sigue en vigencia; default TRUE
ingested_at	TIMESTAMP WITH TZ			NO	Fecha en que fue cargado al sistema CACIF

4. Descripción de Relaciones

Tabla Origen	Tabla Destino	Cardinalidad	Descripción
ESTUDIANTE	CONVERSACION	1 : N	Un estudiante puede tener múltiples conversaciones a lo largo del tiempo. Si se elimina el estudiante, sus conversaciones se eliminan en cascada.
CONVERSACION	MENSAJE	1 : N	Una conversación agrupa N turnos de diálogo. La eliminación en cascada asegura integridad referencial.
MENSAJE	FUENTE_CITADA	1 : N	Cada respuesta del chatbot (rol=assistant) puede citar 1 o más chunks normativos. Los mensajes del usuario (rol=user) no tienen citas.
FUENTE_CITADA	CHUNK_NORMATIVO	N : 1	Varios mensajes distintos pueden citar el mismo chunk normativo. Esto permite identificar los fragmentos más frecuentemente consultados.
CHUNK_NORMATIVO	DOCUMENTO_NORMATIVO	N : 1	Un documento normativo (PDF) se divide en múltiples chunks durante la ingesta. Todos los chunks de un mismo PDF referencian el mismo documento origen.